

به نام خدا

شماره دانشجویی : ۴۰۲۱۰۶۶۰۴

محمد رضا منعمیان



Mohammad Reza Monemian

bioinformatic

سوال اول (


قسمت آ :

ابتدا به بیان دو روش می پردازیم :

روش **qpcr** : در این روش DNA ورودی با استفاده از DNA POLYMERISE و PRIMER هایی که وارد می کنیم تکثیر می شود و ما حضور یا عدم حضور توالی که primer آن را وارد کردیم در ژنوم خود بررسی کنیم. توجه داریم که DNA همه سلول های بدن یک جاندار مانند هم است و در سلول های مختلف بیان ژن است که متفاوت است بنابراین این روش نمی تواند اینکه چه ژنی در ژنوم ورودی بیان شده است را بررسی کند.

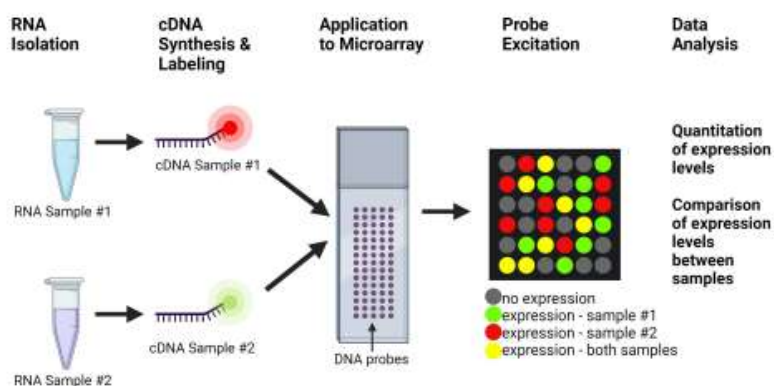
روش **qpcr-rt** : در این روش ورودی ما به جای DNA ، mRNA است. آنزیمی به نام Reverse transcription وجود دارد که می تواند معکوس عملیات ترجمه را انجام دهد یعنی mRNA را به cDNA تبدیل کند. با استفاده از این آنزیم می توان ابتدا mRNA ورودی را به cDNA تبدیل کرد و با تکثیر آن به روش قبلی مستقیماً بیان ژن را بررسی کرد.

بنابراین به طور خلاصه روش توالی یابی **qRT-PC** برای اندازه گیری بیان ژن، از **qPCR** متمایز است زیرا شامل یک مرحله حیاتی به نام **رونوشت برداری معکوس** است که در ابتدای فرآیند انجام می شود. از آنجایی که **PCR** فقط می تواند رشته های DNA را تکثیر و اندازه گیری کند، مرحله **RT** با استفاده از آنزیم **رونوشت بردار معکوس**، اطلاعات **RNA** (که نشان دهنده بیان ژن است) را به یک رشته **DNA** مکمل تبدیل می کند. این **cDNA** سپس به عنوان الگو در واکنش **qPCR** استفاده می شود و به این ترتیب، اندازه گیری کمی محصول نهایی به طور معکوس میزان **RNA** اولیه و در نتیجه سطح بیان ژن را در نمونه نشان می دهد، که هدف اصلی در مطالعات بیان ژن است.

qRT-PCR

در روش **micro array** برای مثال ۲ ژنومی که می‌خواهیم بررسی کنیم ابتدا لیبل گذاری می‌شود. سپس آنها بر روی میکروشیپی که دارای پراب های متعدد است قرار می‌گیرد. هر کدام از این پراب ها مکمل یک ژن خاص هستند که هدف مطالعه ماست . وقتی ژنومی مکمل آن پراب باشد به آن نقطه متصل می‌شود. در ادامه هر چقدر نور ساطع شده بیشتر باشد یعنی مولکول DNA بیشتری به آن پراب متصل شده است و این یعنی شدت سیگنال هر نقطه نشان دهنده میزان فراوانی RNA آن ژن در نمونه اصلی است. اما چرا امروزه از روش های NGS بیشتر استفاده می‌شود:

Microarray



۱. توانایی اکتشافی :

روش **micro array** محدود به ژن هایی است که پروب های آن از قبل به میکروچیپ متصل شده باشد. اگر در نمونه ما یک جهش یا ژن جدیدی بیان شده باشد این روش قادر به پیدا کردن آن نیست. اما در مقابل روش های جدید می‌تواند کل ترانسکریپتوم را بخواند به همین دلیل می‌تواند به طور همزمان ژن های جدید و ادغام های ژنی و ایزوفروم های پیرایشی را بررسی کند.

۲. دقت و محدوده دینامیکی:

همانطور که اشاره شد روش **microarray** بیان ژن ها را بر اساس شدت فلوروسنت می‌سنجد اما به دلیل وجود نویز و یا اشباع سیگنال این روش دارای محدوده دینامیکی کمی است و این باعث می‌شود این روش نتواند دقت بالایی برای بیان های کم محدوده دینامیکی وسیع و مناسبی پیدا کند اما در مقابل روش های جدید با



استفاده از شمارش مطلق تعداد دفعاتی که توالی آن ژن خوانده می شود صورت می گیرد و این امر سبب ایجاد دقت بالا حتی برای بیان های کم می شود.

۳. واریانت های ساختاری :

روش microarray تنها میزان فراوانی را اندازه می گیرد اما روش های NGS می تواند ساختار ها و واریانت های ژنی را نیز تشخیص دهد.

۴. هزینه نهایی روش های NGS بسیار به صرفه تر است.

قسمت ج:

تولید کلاستر فرآیندی است که در آن، هر مولکول DNA الگو روی flow cell تکثیر می شود تا صدها هزار کپی از یک توالی واحد در یک نقطه مشخص جمع شوند. در اصل ایجاد کلاستر در روش illumine به این دلیل ضروری است که سیگنال نور ساطع شده تقویت شود. در روش توالی یابی از طریق سنتز در هر چرخه، فقط یک نوکلئوتید با یک برچسب فلوئورسنت به رشته های DNA در حال رشد متصل می شود. سیگنال ساطع شده از یک مولکول بسیار ضعیف است و توسط دوربین های دستگاه به درستی قابل تشخیص نیست. اما وقتی میلیون ها کپی یکسان از توالی در یک کلاستر جمع می شوند، سیگنال های نوری آن ها با هم جمع شده و به یک سیگنال نوری قوی تبدیل می شوند که دوربین با وضوح بالا می تواند آن را به راحتی ثبت کند.

از طرف دیگر هر کلاستر توالی یک قطعه DNA الگو را به طور مستقل نشان می دهد. ایجاد میلیون ها کلاستر روی یک سطح جریان خانه، دستگاه می تواند میلیون ها توالی متفاوت را به طور همزمان و موازی بخواند. این ویژگی باعث شده است که illumine به یک روش توالی یابی نسل جدید بدل شود.

قسمت د :

خیر لزوماً به این معنی نیست و می تواند به دلیل دلایل فنی و بیولوژیکی متعددی باشد که به سطح بیان واقعی RNA ارتباطی نداشته باشد برای مثال :



۱. محدودیت های ساخت و طراحی پروب : اگر توالی پروب DNA مربوط به آن ژن درست طراحی نشده باشد مثال طول نامناسب یا ساختار ثانویه پیچیده کارایی به شدت کاهش می یابد و این باعث می شود cDNA کمتری به آن متصل شود و سیگنال ضعیف تری ساطع کند.

همچنین اگر در توالی ژن مورد آزمایش جهش یا واریانتهی اتفاق افتاده باشد بطوریکه با توالی پروب طراحی شده متفاوت باشد اتصال به درستی رخ نمی دهد و این امر باعث کاهش شدید سیگنال می شود حتی اگر بیان ژن بالا باشد.

۲. مشکلات مربوط به آماده سازی :

اگر RNA آن ژن خاص در مراحل اولیه استخراج یا آماده سازی (قبل از سنتز DNA) تخریب شده باشد، مواد اولیه کمی برای برچسب گذاری فلوئورسنت در دسترس خواهد بود، در نتیجه سیگنال ضعیف می شود. همچنین کارایی برچسب فلوئورسنت نیز در مرحله سنتز می تواند کاهش یابد و در نتیجه با وجود بیان کافی سیگنال ساطع شده ضعیف باشد.

۳. نويز :

اگر سطح بیان یک ژن به صورت طبیعی بسیار پایین باشد، سیگنال آن ممکن است به سختی از نويز پس زمینه تفکیک شود و به اشتباه به عنوان بیان کم شناخته شود.

(سوال دوم)

قسمت الف :

در روش global عادی ما به دنبال یک assignment به صورت سراسری هستیم بطوریکه امتیاز منفی که برای گپ در نظر می گیریم ثابت است اما در حالت affine یک امتیاز منفی زیاد برای باز شدن گپ در نظر گرفته و امتیاز کمتری را به ادامه دادن گپ نسبت می دهیم.

برای حل این مسئله سه ماتریس upper , lower , middle تعریف می کنیم به صورتیکه در ماتریس middle تنها می توان به صورت قطری حرکت کرد. در ماتریس upper به صورت افقی و در ماتریس lower تنها می توان به صورت عمودی رفت. برای پر کردن سه ماتریس گفته شده ابتدا به بیان چگونگی مقدار دهی اولیه آنها می پردازیم :

برای ماتریس middle :

$$M_{00} = 0, M_{i0} = -\infty, M_{0j} = -\infty$$

برای ماتریس upper :

$$U_{i0} = -\infty, U_{0j} = gapopen + (j - 1)gapextend ,$$

برای ماتریس lower :

$$l_{0j} = -\infty, L_{i0} = gapopen + (i - 1)gapextend$$


روابط بازگشتی نیز به صورت زیر خواهد بود :

$$L[i][j] = \max(L[i - 1][j] + gapextend, M[i - 1][j] + gapopen)$$

$$U[i][j] = \max(U[i][j - 1] + gapextend, M[i][j - 1] + gapopen)$$

$$M[i][j] = \max(M[i - 1][j - 1], L[i-1][j-1], U[i-1][j-1]) + score(v_i, w_j)$$

که در اینجا منظور از score این است که اگر match رخ داد امتیاز آن و اگر mismatch رخ داد امتیاز مربوط به آن لحاظ شود.



σ - σ : Jumping penalty is assigned to moving from the main level to either the upper level or the lower level
 ϵ - ϵ : Gap extension penalty for each continuation on a level other than the main level)

$$\begin{aligned} lower_{i,j} &= \max \begin{cases} lower_{i-1,j} - \epsilon \\ middle_{i-1,j} - \sigma \end{cases} \\ middle_{i,j} &= \max \begin{cases} lower_{i,j} \\ middle_{i-1,j-1} + Score(v_i, w_j) \\ upper_{i,j} \end{cases} \\ upper_{i,j} &= \max \begin{cases} upper_{i,j-1} - \epsilon \\ middle_{i,j-1} - \sigma \end{cases} \end{aligned}$$

قسمت ب :

در این قسمت به هم ترازوی دو رشته داده شده با استفاده از الگوریتمی که بیان کردیم می‌پردازیم. برای این کار سه ماتریس مورد نظر را پر می‌کنیم :



ماتریس upper :

		T	C	T	C
	*	*	*	*	*
A	-4	*	*	*	*
T	-5	-7 , m	-11,m	-12,m	-13,m
T	-6	-3,m	-10,m	-6,m	-14,u
C	-7	-4,u	-6,m	-2,m	-9,m

ماتریس middle :

		T	C	T	C
	0	*	*	*	*
A	*	-3,m	-7,l	-8,l	-9,l
T	*	1,u	-6,m	-2,m	-11,m
T	*	0,u	-2,m	2,l	-5,m
C	*	-9,u	5,m	-5,m	7,m

ماتریس lower :

		T	C	T	C
	*	-4	-5	-6	-7
A	*	*	-7,m	-8,l	-9,l
T	*	*	-3,m	-4,l	-5,l
T	*	*	-4,m	-5,l	-2,m
C	*	*	-13,m	1,m	0,l

توجه داریم که منظور از * منفی بی نهایت است. همچنین حرفی که کنار امتیاز هر خانه نوشته شده است نشان دهنده جهت حرکت در backtrack است.

همانطور که مشاهده می‌کنیم امتیاز خانه آخر جدول middle برابر با ۷ است و match دو C در آن است. طبق حرف نوشته شده باید قطری حرکت کرد که به خانه ۳ و ۳ ماتریس middle می‌رسیم. که در آن match دو حرف T را داریم. طبق حرف نوشته شده در این خانه باید به خانه ۲ و ۲ ماتریس lower برویم و این یعنی در رشته در محور عمودی ماتریس یک گپ ایجاد شده است. اما چون حرف نوشته شده در این خانه m هست این گپ ادامه پیدا نمی‌کند و باید به خانه ۱ و ۲ از ماتریس middle برویم که در آنجا یک match برای حرف T رخ می‌دهد. در ادامه با توجه به حرف u باید به خانه ۱ و ۰ ماتریس upper حرکت کنیم و این یعنی در رشته ای که در حالت افقی ماتریس ها قرار گرفته است باید یک گپ ایجاد شود. بنابراین هم ترازای نهایی به صورت زیر است



-TCTC
AT-TC

که اگر امتیاز نهایی آن را نیز محاسبه کنیم برابر با ۷ خواهد بود.

سوال سوم)

منظور از قیچی i, j در رشته X, Y بدین معناست که در هم تراز می‌شوند که به عنوان جواب خروجی داده می‌شود. حتماً دو کاراکتر x_i, y_j روی هم قرار بگیرند. برای حل این مسئله دو بار باید از الگوریتم نیدلمن وانش استفاده کنیم یکی برای محاسبه امتیاز پیشوند و یکی برای محاسبه امتیاز پسوند. جدول F را برای پیشوند و جدول E را برای پسوند در نظر می‌گیریم. روابط بازگشتی و مقدار دهی اولیه آنها به صورت زیر است:

جدول F :

خانه ۰ و ۰ آن برابر با صفر است و دیگر درایه های سطر اول و ستون اول آن به صورت زیر محاسبه می‌شود:

$$F[i][0] = (i - 1) \text{costofgap}, F[0][j] = (j - 1) \text{costofgap}$$

بقیه سطر و ستونها به صورت بازگشتی به روش زیر محاسبه می‌شوند:

$$F[i][j] = \max(F[i - 1][j - 1] + \text{score}(x_i, y_j), F[i - 1][j] + \text{costofgap}, F[i][j - 1] + \text{costofgap})$$

این جدول برای هر i, j بهترین امتیاز پیشوند را محاسبه می‌کند.

جدول دوم یعنی E برای محاسبه بهترین امتیاز پسوند است. مقدار دهی اولیه آن به صورت زیر و یک طور به شکل مکمل جدول F است:

$$E[i][n] = (m - i) \text{costofgap}, G[m][j] = (n - j) \text{costofgap}$$

به عبارت دیگر سطر آخر و ستون آخر به ترتیب با حرکت به طرف چپ و حرکت به طرف بالا باید به صورت تساعدی با هزینه گپ پر شود.

برای پر کردن بقیه جدول باید از رابطه بازگشتی زیر استفاده کنیم:

$$E[i][j] = \max(E[i + 1][j + 1] + \text{score}(x_i, y_j), E[i + 1][j] + \text{costofgap}, E[i][j + 1] + \text{costofgap})$$

حالا با استفاده از این دو جدول با فرمول زیر جدول G را پر می‌کنیم:

$$G[i][j] = F[i - 1][j - 1] + \text{score}(x_i, y_j) + E[i + 1][j + 1]$$

منظور از score نیز یعنی اگر مچ شد امتیاز مچ و اگر نشد امتیاز mismatch محاسبه شود.



واضح است که برای انجام این الگوریتم کافی است دو بار دو حلقه تو در تو به اندازه طول رشته اول و دوم بزنیم یعنی زمان اجرای آن از اردر $|x||y|$ خواهد شد.